



Ciencia de Datos vs Econometría

Dos formas de aprender de los datos: predecir,
explicar y decidir mejor

Círculo de Ciencia de Datos y Econometría

Mapa de la presentación

1. Idea central
2. Diferencias clave
3. Flujos y herramientas
4. Casos de estudio
5. Convergencia y riesgos
6. Cierre y fuentes

La ruta es deliberada: primero aclaramos la pregunta, luego comparamos estándares de evidencia, después bajamos a casos y cerramos con la convergencia moderna.

La econometría pregunta: “¿qué efecto tiene X sobre Y?”

La ciencia de datos pregunta: “¿qué patrón ayuda a predecir o automatizar mejor?”

Econometría

- ▶ Busca efectos, mecanismos y parámetros interpretables.
- ▶ Se preocupa por identificación, supuestos e inferencia.
- ▶ Una buena respuesta debe ser creíble, no solo ajustarse a los datos.

Ciencia de datos

- ▶ Busca predicción, clasificación, segmentación y automatización.
- ▶ Se preocupa por generalización, escalabilidad y operación.
- ▶ Una buena respuesta debe funcionar fuera de muestra.


Por qué no basta decir “estadística vs algoritmos”

- ▶ Ambas usan estadística, regresión, validación, programación y datos.
- ▶ Ambas pueden predecir; ambas pueden ayudar a explicar.
- ▶ La diferencia importante aparece cuando hay tensión entre objetivos.

Criterio de éxito:

Econometría: interpretación causal o estructural defendible.


Ciencia de datos: utilidad predictiva u operativa robusta.



Fuente: Breiman (2001); Shmueli (2010).

Raíces históricas: dos tradiciones

Econometría



Ciencia de datos y puente moderno



Dos tradiciones separadas que convergen: economía y probabilidad de un lado, computación y análisis del otro.

Fuente: Frisch; Haavelmo (1944); Tukey (1962); Cleveland (2001); Donoho (2017); Card, Angrist, Imbens (2021).

La pregunta manda sobre la herramienta

Cuando la pregunta es causal

- ▶ ¿Subir el salario mínimo cambia el empleo?
- ▶ ¿La educación aumenta el salario?
- ▶ ¿Funcionó una política pública?
- ▶ ¿Qué supuesto hace creíble el efecto?

Cuando la pregunta es predictiva

- ▶ ¿Quién dejará de pagar un crédito?
- ▶ ¿Qué producto conviene recomendar?
- ▶ ¿Qué ventas esperamos mañana?
- ▶ ¿Cómo automatizar una decisión repetida?


Regla divulgativa: si quieres saber “qué pasaría si cambio X”, piensa econométricamente. Si quieres anticipar “qué pasará dado lo que observo”, piensa como ciencia de datos.

Fuente: Angrist y Pischke (2009); IBM CRISP-DM; scikit-learn.

Explicar no es lo mismo que predecir

Inferencia causal


Objetivo: estimar un efecto defendible



- Pregunta: efecto de X sobre Y .
- Informa β e incertidumbre.
- Requiere identificación.

Predicción

Objetivo: anticipar bien casos nuevos



- Pregunta: valor esperado.
- Minimiza error fuera de muestra.
- Permite funciones flexibles.

Fuente: Pearl (2009), Causality; Shmueli (2010).

Comparación rápida

Dimensión	Econometría	Ciencia de datos
Pregunta	qué efecto tiene X sobre Y	qué patrón ayuda a predecir o automatizar desempeño fuera de muestra y utilidad operativa
Éxito	identificación creíble e inferencia válida	
Validación	pruebas, intervalos, placebo y robustez	train/test, validación cruzada y métricas
Producto	evaluación, elasticidad, informe causal	panel de control, API, puntuación, recomendador
Riesgo	confundir correlación con causalidad	caja negra, sesgo o fuga de información

No cambia solo la técnica: cambia el estándar de evidencia.

Flujos de trabajo: dos formas de ordenar el problema

Econometría aplicada

Pregunta causal



Diseño de identificación



Estimación



Inferencia y robustez



Interpretación

Ciencia de datos

Problema de negocio



Datos y preparación



Modelado y ajuste
de hiperparámetros



Evaluación fue-
ra de muestra



Despliegue y monitoreo

Fuente: IBM CRISP-DM; Angrist y Pischke (2009); NIST AI RMF (2023).

Herramientas: cajas distintas, piezas compartidas

Econometría

MCO, IV, DiD, RDD,
panel, GMM, ARIMA,
VAR, pruebas de hipótesis.

Zona común

Regresión, regularización,
validación, series
temporales, Python, R.

Ciencia de datos

Árboles, bosques aleatorios,
boosting, redes neuronales,
agrupamiento,
canalizaciones.

R

Python

Stata

statsmodels

scikit-learn


TensorFlow

Fuente: statsmodels; scikit-learn; TensorFlow; Stata documentation.

Mini-caso econométrico: salario mínimo


Pregunta: ¿subir el salario mínimo redujo el empleo en restaurantes de comida rápida?

- ▶ **Tratamiento:** Nueva Jersey sube el salario mínimo.
- ▶ **Comparación:** Pensilvania sirve como grupo cercano.
- ▶ **Idea:** mirar diferencias antes/después y entre lugares.
- ▶ **Lección:** la credibilidad nace del diseño.



Fuente: Card y Krueger (1994), American Economic Review; NBER Working Paper 4509.

Mini-caso de ciencia de datos: pobreza desde satélites




Pregunta: ¿podemos estimar bienestar donde las encuestas son escasas o caras?

- ▶ **Señales:** luces nocturnas e imágenes diurnas.
- ▶ **Modelo:** aprendizaje automático para construir variables proxy.
- ▶ **Uso:** focalizar recursos donde faltan encuestas.
- ▶ **Lección:** predicción útil para medir mejor.

Fuente: Jean et al. (2016), Science.

El puente: aprendizaje automático causal



La frontera moderna no pregunta “¿econometría o aprendizaje automático?”, sino “¿cómo usar modelos flexibles sin perder inferencia causal creíble?”.

Fuente: Mullainathan y Spiess (2017); Athey e Imbens (2019); Chernozhukov et al. (2018); Lechner (2023).

Riesgos que una publicación sí debe nombrar

Sesgo

Los datos pueden heredar o amplificar exclusiones, desigualdades y decisiones pasadas.

Caja negra

En decisiones de alto impacto, explicar después puede no bastar: conviene diseñar modelos inherentemente interpretables.

Reproducibilidad

Si no puede reproducirse, documentarse y auditarse, es débil como base para decisiones importantes.

El problema no es usar modelos complejos. El problema es usarlos sin gobernanza, sin validación y sin responsabilidad.

Fuente: Barocas y Selbst (2016); Rudin (2019); NIST AI RMF (2023); Donoho (2017).

Tres preguntas para público no técnico

1. ¿Queremos explicar un efecto o acertar una predicción?
2. ¿Qué pasa si el modelo se equivoca?
3. ¿A quién debemos justificar la decisión: cliente, regulador, juez, ministro, usuario?

Econometría

Un laboratorio imperfecto para aislar causas.

Ciencia de datos

Una sala de control para detectar señales útiles.

Fuente: Shmueli (2010); Rudin (2019); NIST AI RMF (2023).

Las mejores decisiones no nacen de tomar partido entre econometría y ciencia de datos.

Nacen de saber cuándo necesitamos **causalidad creíble**, cuándo necesitamos **predicción útil** y cuándo necesitamos **ambas**.

Identificación

Predicción

Interpretabilidad

Escalabilidad

Responsabilidad

Fuente: Lechner (2023); Chernozhukov et al. (2018).

Bibliografía seleccionada I

Haavelmo, T. (1944). *The Probability Approach in Econometrics*. Econometrica.

Tukey, J. W. (1962). The Future of Data Analysis. *Annals of Mathematical Statistics*.

Cleveland, W. S. (2001). Data Science: An Action Plan for Expanding Statistics. *International Statistical Review*.

Breiman, L. (2001). Statistical Modeling: The Two Cultures. *Statistical Science*.

Shmueli, G. (2010). To Explain or to Predict? *Statistical Science*.

Donoho, D. (2017). 50 Years of Data Science. *J. Computational and Graphical Statistics*.

Card, D. & Krueger, A. B. (1994). Minimum Wages and Employment in NJ and PA. *American Economic Review*.

Mullainathan, S. & Spiess, J. (2017). Machine Learning: An Applied Econometric Approach. *Journal of Economic Perspectives*.

Nota: Bibliografía completa, con DOI y enlaces, disponible en el documento original.

Bibliografía seleccionada II

Jean, N. et al. (2016). Combining satellite imagery and machine learning to predict poverty. *Science*.

Chernozhukov, V. et al. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*.

Athey, S. & Imbens, G. W. (2019). Machine Learning Methods That Economists Should Know About. *Annual Review of Economics*.

Barocas, S. & Selbst, A. D. (2016). Big Data's Disparate Impact. *California Law Review*.

Rudin, C. (2019). Stop Explaining Black Box ML Models for High-Stakes Decisions. *Nature Machine Intelligence*.

NIST (2023). *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*. NIST AI 100-1.

IBM (2024). CRISP-DM View. Documentación oficial IBM.

Lechner, M. (2023). Causal Machine Learning and its Use for Public Policy. *Swiss Journal of Economics and Statistics*.

Nota: DOI y URLs completos disponibles en la versión extendida de este documento.